

CAPSTONE — SISTEMAS INTELIGENTES Y COMPUTACIONALES

LINE

Auditor Médico Digital

Detección predictiva de inconsistencias en prefacturación mediante inteligencia artificial

Equipo SICortex

Jefersson Aldair Oliveros (líder)

Jazmine Alexandra Acosta Bejarano

Iván Yesid Cristancho Plata

Isabella Andrea Cuesta Niebles

Catalina del Rocío Pantoja Ordóñez

Samsung Innovation Campus & Universidad del Rosario

Capstone — Sistemas Inteligentes y Computacionales

Reto empresarial: Health & Life IPS SAS

Agosto de 2026

Índice

Índice	2
Introducción	4
Contexto del problema.....	4
Objetivo del proyecto.....	4
Impacto esperado.....	4
Metodología	4
Fuentes de datos	4
Ingeniería de variables	5
<i>Nota sobre la variable coincide_codigo_cups</i>	5
Pipeline tabular-to-image (CNN).....	5
Modelos implementados	6
CNN MobileNetV2 (requisito del curso — transfer learning)	6
Random Forest (modelo de comparación).....	6
XGBoost (modelo final elegido para producción)	6
NVIDIA Nemotron-3-nano-8B (modelo utilizable)	7
Desarrollo de la aplicación	8
Backend FastAPI	8
Frontend HTML/JavaScript.....	8
<i>Análisis individual</i>	8
<i>Importación masiva</i>	8
<i>Selector de modelos y navegación</i>	8
Arquitectura del sistema	9
Resultados	10
Dataset	10
Tipos de alertas detectadas.....	10
Recomendaciones automáticas	10
Comparación de los cuatro modelos.....	10
Conclusión de la comparación.....	11
Importancia de variables — XGBoost.....	11
Impacto económico estimado	11

Consideraciones éticas	12
Protección de datos sensibles	12
Mitigación de sesgos	12
Transparencia	12
Responsabilidad	12
Cumplimiento normativo (Ley 1581/2012 e ISO/IEC 27001:2022)	12
Documentación de cumplimiento	12
Controles técnicos implementados	13
Actualizaciones en el frontend	13
Estado actual y próximos pasos	13
Enlaces y recursos	14
Equipo SICortex	14
Jefersson Aldair Oliveros (líder del proyecto)	14
Jazmine Acosta	14
Isabella Andrea Cuesta Niebles	14
Catalina del Rocío Pantoja Ordóñez	14
Iván Yesid Cristancho Plata	14
Cronograma de ejecución	15
Fase 1 (13-19 de julio): datos y modelos base — completado	15
Fase 2 (20-24 de julio): modelado avanzado — completado	15
Fase 3 (24-26 de julio): interfaz y batch — completado	15
Fase 4 (27 de julio - 2 de agosto): consolidación — completado	15
Fase 5 (3-4 de agosto): cierre — en progreso	15
Conclusiones	15

(Este índice se actualiza automáticamente: clic derecho → Actualizar campos, o F9.)

Introducción

Contexto del problema

Health & Life IPS SAS enfrenta un desafío significativo en su proceso de facturación: inconsistencias entre lo registrado en la historia clínica (HC) y lo efectivamente facturado a las EPS en las prefacturas (PF). Estas inconsistencias generan dos tipos de pérdidas económicas.

- Glosas por sobrefacturación: servicios facturados sin soporte clínico real, rechazados por las EPS.
- Fugas de ingresos: procedimientos realizados y registrados en HC que no aparecen en la prefactura.

Actualmente, la auditoría se realiza de forma retrospectiva después del envío a cobro, lo que limita la capacidad de corrección preventiva.

Objetivo del proyecto

Construir un modelo de inteligencia artificial que detecte, antes del envío a cobro, inconsistencias entre la historia clínica y la prefactura médica, desarrollado entre el 13 de julio y el 4 de agosto de 2026, con el fin de que Health & Life IPS SAS cuente con un filtro preventivo que reduzca las glosas por sobrefacturación y las fugas de ingreso por servicios no facturados.

Impacto esperado

- Reducción de glosas: detección temprana de servicios sin soporte clínico.
- Recuperación de ingresos: identificación de procedimientos no facturados.
- Eficiencia operativa: priorización automática de casos de alto riesgo para revisión manual.
- Transición: reemplazo de auditoría retrospectiva por validación temprana.

Metodología

Fuentes de datos

El proyecto integra cinco fuentes de datos entregadas por Health & Life IPS SAS:

Tabla 1. Fuentes de datos del proyecto

Fuente	Registros	Descripción
Pacientes	300	Edad, sexo, EPS, afiliación, ciudad
Atenciones	1,200	Diagnóstico CIE10, médico, sede
Historia clínica	—	Procedimientos realizados con soporte clínico
Prefacturación	—	Ítems facturados (CUPS, cantidad, valores)

Tabla de cruce	3,126	Etiqueta objetivo: comparación HC vs. PF
-----------------------	-------	--

Ingeniería de variables

El dataset maestro se construye a nivel de cada cruce HC-prefectura con las siguientes transformaciones:

- Limpieza de datos: tratamiento de nulos (numéricos → 0, categóricos → "SIN_DATO").
- Ingeniería de variables: coincidencia de código CUPS, diferencia de cantidades (realizada vs. facturada), ratio de cantidad, presencia de soporte clínico y días de diferencia entre facturación y atención.
- Exclusión de variables filtrantes: se excluyen columnas que filtrarían la respuesta (tipo de alerta, severidad y derivadas).

Nota sobre la variable coincide_codigo_cups

Durante el desarrollo se identificó que coincide_codigo_cups concentra la mayor parte de la importancia del modelo XGBoost (ganancia = 65.7%, ver sección de Resultados). Se verificó que esta variable no constituye fuga de datos: se calcula comparando el código CUPS facturado contra el código CUPS registrado en la historia clínica, ambos disponibles antes de la decisión de auditoría, y refleja directamente la regla de negocio central del proyecto (CUPS facturado distinto del CUPS en HC produce la alerta CODIGO_NO_COINCIDE). Su peso dominante es, por tanto, coherente con el problema y no un artefacto de fuga.

Pipeline tabular-to-image (CNN)

Para el modelo CNN, los datos tabulares se convierten en imágenes sintéticas siguiendo el proceso que se muestra en la Figura 1.

CSV/JSON → Imputación de nulos → Escalado numérico (6 columnas) → One-Hot Encoding (13 columnas → 111 features) → Posicionamiento t-SNE en grid 32×32 → Normalización global min-max → CNN MobileNetV2 → probabilidad [0, 1] → Threshold (.pkl) → CONSISTENTE / INCONSISTENTE

Figura 1. Pipeline tabular-to-image para el modelo CNN

Las columnas utilizadas en este pipeline son las siguientes:

- Numéricas (6): edad, cantidad_realizada, cantidad_facturada, valor_unitario, valor_total, mes_atencion.
- Categóricas (13 → 111 dummies): sexo, eps_atencion, tipo_afiliacion, ciudad, tipo_documento, tipo_atencion, sede, tipo_item, soporte_clinico, grupo_etario, diagnostico_principal_cie10, medico_tratante, profesional_responsable.

Modelos implementados

Se compararon cuatro enfoques de modelado sobre el mismo dataset maestro (partición 70/30 estratificada, semilla fija) con el fin de justificar la elección final con evidencia empírica, tal como exige el plan de acción del proyecto.

CNN MobileNetV2 (requisito del curso — transfer learning)

Arquitectura: modelo base MobileNetV2 preentrenado en ImageNet, con entrada de imágenes sintéticas de 32×32×3 píxeles y salida de probabilidad de inconsistencia [0, 1].

Entrenamiento: se ejecuta en dos fases. En la primera, la base permanece congelada y solo se entrenan las capas superiores; en la segunda, se realiza un ajuste fino (fine-tuning) completo con una tasa de aprendizaje reducida (10 capas entrenables, 144 congeladas). Se utiliza función de pérdida focal (focal loss) para manejar el desbalance de clases (20.8% positivos), y el umbral de decisión se optimiza en el conjunto de validación.

Entre sus ventajas se cuentan el aprovechamiento del conocimiento visual preentrenado, la capacidad de detectar patrones complejos en datos tabulares transformados y el cumplimiento del requisito del curso de aprendizaje por transferencia. Sin embargo, como se muestra en la sección de Resultados, su recall es notablemente más bajo que el de los modelos tabulares clásicos, lo cual es consistente con el ruido espacial artificial que introduce la conversión de datos tabulares a imagen.

Random Forest (modelo de comparación)

Arquitectura: bosque aleatorio de 400 árboles, con `class_weight` balanceado y `min_samples_leaf` de 2, evaluado bajo dos escenarios de variables (producción completa y las mismas variables usadas por la CNN).

Su propósito fue servir como punto de referencia tabular clásico para decidir si, frente al requisito de usar CNN con transfer learning, convenía adoptar en su lugar un modelo tabular puro para producción. Random Forest superó ampliamente a la CNN en AUC-ROC y en puntaje F1 (ver sección de Resultados), lo que confirmó que el problema tiene una estructura fuertemente tabular.

XGBoost (modelo final elegido para producción)

Arquitectura: gradient boosting basado en árboles de decisión, optimizado mediante búsqueda de hiperparámetros (tasa de aprendizaje, profundidad máxima, número de estimadores, `scale_pos_weight`) y validación cruzada de 5 particiones. Variables: `coincide_codigo_cups`, `diferencia_cantidad`, `ratio_cantidad`, `tiene_soporte_clinico` y `dias_diferencia`, además de variables demográficas y de atención.

XGBoost obtuvo el mejor desempeño global de los cuatro enfoques evaluados, con una precisión particularmente alta que minimiza los falsos positivos, un criterio operativo relevante para no saturar al equipo auditor con alertas incorrectas. Por este resultado, es el modelo recomendado y utilizado para

producción, mientras que la CNN se mantiene documentada y disponible en la aplicación como cumplimiento del requisito de transfer learning del curso.

NVIDIA Nemotron-3-nano-8B (modelo utilizable)

Arquitectura: modelo de lenguaje preentrenado de NVIDIA, de 8 mil millones de parámetros, optimizado para razonamiento y accesible mediante API (requiere una NVIDIA_API_KEY).

Funcionalidad: recibe el contexto clínico completo (diagnóstico, ítems de prefactura, ítems de historia clínica y cruces), genera un análisis detallado con recomendación, proporciona razonamiento clínico explicativo y puede seleccionarse en la interfaz junto con los demás modelos. No requiere entrenamiento específico y funciona como capa de validación externa y complemento cualitativo a las predicciones de CNN y XGBoost.

Desarrollo de la aplicación

Backend FastAPI

El backend está desarrollado en Python 3.11 o superior con FastAPI, se ejecuta en un servidor Uvicorn por el puerto 8000 y utiliza una base de datos SQLite (linea.db), migrable a SQL Server o MySQL.

Tabla 2. Endpoints principales del backend

Método	Ruta	Descripción
GET	/api/health	Estado del servidor y del modelo
GET	/api/modelos	Lista de modelos de IA disponibles
POST	/api/prefectura/analizar	Análisis individual de prefectura
POST	/api/prefectura/analizar-lote	Importación masiva (procesamiento por lotes)
GET	/api/paciente/{id}	Detalle de paciente y atenciones
POST	/api/paciente/verificar-adres	Consulta de BDUA (afiliación)

Frontend HTML/JavaScript

El frontend utiliza HTML5 y JavaScript nativo, con Tailwind CSS para los estilos y Material Symbols para los íconos. Entre las funcionalidades implementadas se encuentran las siguientes.

Análisis individual

- Formulario de datos del paciente.
- Carga de archivo CSV de prefectura.
- Verificación BDUA (afiliación activa).
- Cruce automático entre historia clínica y prefectura.
- Resultados con alertas y recomendaciones.

Importación masiva

- Carga de archivo CSV con múltiples prefecturas (100 a 20,000 registros).
- Procesamiento por lotes con progreso en tiempo real.
- Resumen global (total, aprobados, rechazados, en revisión).
- Tabla detallada por prefectura, con filtros (todos, aprobados, en revisión, rechazados).
- Exportación de resultados a CSV.

Selector de modelos y navegación

La interfaz permite alternar entre CNN local (MobileNetV2), XGBoost y NVIDIA Nemotron, con el selector sincronizado entre la barra lateral y la pantalla de importación masiva. La navegación incluye las

secciones de validación (análisis individual), importación masiva y soporte, con estados activos sincronizados.

Arquitectura del sistema

Frontend HTML/JS → API REST (JSON) → Backend FastAPI (server.py) → SQLite (linea.db) + Modelo CNN local + XGBoost local + NVIDIA Nemotron (API externa)

Figura 2. Arquitectura general del sistema LINE

Resultados

Dataset

Tabla 3. Composición del dataset

Métrica	Valor
Total de cruces	3,126
Pacientes únicos	300
Atenciones únicas	1,200
Consistentes	2,477 (79.2%)
Inconsistentes	649 (20.8%)

Tipos de alertas detectadas

Tabla 4. Tipos de alerta y su significado

Alerta	Significado
SIN_SOPORTE_CLINICO	Servicio facturado sin registro en historia clínica
CODIGO_NO_COINCIDE	CUPS facturado distinto del CUPS en historia clínica
CANTIDAD_DISCORDANTE	Cantidad facturada distinta de la cantidad realizada
DIAGNOSTICO_NO_RELACIONADO	Diagnóstico CIE10 no relacionado con el procedimiento facturado
NO_FACTURADO	Procedimiento en historia clínica que no aparece en la prefactura (fuga de ingreso)

Recomendaciones automáticas

- Aprobar: menos de 30% de inconsistencias.
- Revisar: más de 0% de inconsistencias.
- Rechazar: más de 30% de inconsistencias.

Comparación de los cuatro modelos

La Tabla 5 resume el desempeño de los tres modelos evaluados sobre el conjunto de prueba (30% estratificado, semilla fija). Las métricas de la CNN corresponden a la fase de fine-tuning con umbral ajustado para recall; las de XGBoost corresponden al modelo final tras la búsqueda de hiperparámetros y la validación cruzada de 5 particiones (AUC promedio en validación cruzada = 0.881, DE = 0.011, sin señales de sobreajuste).

Tabla 5. Comparación de desempeño entre modelos

Modelo	AUC-ROC	Exactitud	Precisión	Exhaustividad	F1
CNN MobileNetV2	0.673	0.680 ^a	0.343	0.564	0.426
Random Forest	0.919	0.908	0.923	0.610	0.735
XGBoost (final)	0.898	0.926	0.992	0.651	0.786

^a Cada modelo se reporta en su umbral operativo: CNN 0.4273, Random Forest 0.50 y XGBoost 0.896. Con el umbral por defecto (0.50) la CNN sube su exactitud a 0.808, pero su exhaustividad baja a 0.113.

NVIDIA Nemotron no se incluye en la Tabla 5 porque no produce una clasificación binaria directa evaluable con las mismas métricas: opera como una capa de razonamiento cualitativo sobre los resultados de los otros modelos, y no como un clasificador entrenado.

Conclusión de la comparación

XGBoost obtuvo el mejor desempeño global de los cuatro enfoques evaluados (AUC-ROC = 0.898, precisión = 99.2%, F1 = 0.786), superando tanto a Random Forest (AUC = 0.919) como, de forma notable, a la CNN con transfer learning (AUC = 0.748). Random Forest se utilizó específicamente para decidir si convenía migrar el enfoque principal de CNN a un modelo tabular clásico, y su resultado, junto con el de XGBoost, confirmó que sí.

En consecuencia, XGBoost es el modelo recomendado y utilizado para producción en el flujo de decisión automática de la aplicación LINE, mientras que la CNN MobileNetV2 se mantiene implementada, entrenada y disponible como opción seleccionable en la interfaz, cumpliendo así el requisito curricular de aplicar transfer learning con modelos CNN preentrenados. Ambos modelos, junto con NVIDIA Nemotron como capa de validación cualitativa, están integrados en el backend y pueden compararse en tiempo real desde el selector de modelos de la aplicación.

Importancia de variables — XGBoost

La variable con mayor peso en el modelo final es coincide_codigo_cups (ganancia = 65.7%), seguida de tiene_soporte_clinico y diferencia_cantidad. Como se explicó en la sección de Metodología, esta concentración de importancia refleja la regla de negocio central del problema y no constituye una fuga de datos, dado que ambos valores están disponibles antes del envío a cobro.

Impacto económico estimado

La implementación del sistema permitirá reducir las glosas mediante la detección temprana de servicios sin soporte, recuperar ingresos por la identificación de procedimientos no facturados y optimizar los recursos del equipo de auditoría al priorizar automáticamente los casos de mayor riesgo mediante el modelo XGBoost, en lugar de revisar la totalidad de las prefacturas de forma manual.

Consideraciones éticas

Protección de datos sensibles

Los datos de salud se manejan bajo principios de confidencialidad. No se almacenan datos personales identificables en el modelo de IA, y la base de datos local (SQLite) puede migrarse a servidores seguros en producción.

Mitigación de sesgos

Se realiza un análisis de la distribución de los datos por edad, sexo y EPS, se valida la equidad de las predicciones entre grupos demográficos y se contempla un monitoreo continuo de sesgos en producción.

Transparencia

El modelo CNN utiliza un pipeline tabular-to-image documentado, NVIDIA Nemotron proporciona razonamiento explicativo en lenguaje natural, y las reglas de auditoría son transparentes y verificables.

Responsabilidad

El sistema apoya pero no reemplaza el juicio clínico ni la decisión final del equipo auditor; los casos de mayor incertidumbre se priorizan para revisión manual en lugar de una decisión automática.

Cumplimiento normativo (Ley 1581/2012 e ISO/IEC 27001:2022)

El sistema LINE ha sido diseñado considerando los requisitos de la Ley 1581 de 2012 (Protección de Datos Personales en Colombia) y los lineamientos de la norma ISO/IEC 27001:2022 (Seguridad de la Información). A continuación se describen los controles implementados y el estado actual de cumplimiento.

Documentación de cumplimiento

Se crearon seis documentos de cumplimiento normativo ubicados en la carpeta docs/ del proyecto:

- Política de Seguridad de la Información (POLITICA_SEGURIDAD.md) — Define principios de confidencialidad, integridad y disponibilidad, roles y responsabilidades.
- Aviso de Privacidad (AVISO_PRIVACIDAD.md) — Detalla datos recopilados, finalidades, derechos ARCO, transferencia a proveedores y política de retención.
- Análisis de Riesgos (ANALISIS_RIESGOS.md) — Identificación de 12 riesgos con matriz probabilidad-impacto y plan de tratamiento según ISO 27005.

- Política de Retención y Supresión (POLITICA_RETENCION.md) — Plazos de retención por tipo de dato y mecanismos de eliminación segura.
- Inventario de Activos (INVENTARIO_ACTIVOS.csv) — CMDB con 18 activos: datos, modelos, infraestructura y proveedores.
- Guía de Cumplimiento (CUMPLIMIENTO_LEY1581_ISO27001.md) — Documento consolidado con checklist, brechas y plan de acción priorizado.

Controles técnicos implementados

En el backend FastAPI (server.py) se implementaron los siguientes controles de seguridad:

- CORS restringido: el encabezado Access-Control-Allow-Origin se configura mediante la variable de entorno CORS_ORIGINS, con valor por defecto "*" para desarrollo pero configurable para producción.
- Security Headers: se agregaron cabeceras HTTP incluyendo Content-Security-Policy (CSP), X-Frame-Options: DENY, Strict-Transport-Security (HSTS), X-Content-Type-Options: nosniff y Referrer-Policy.
- Logging estructurado: se reemplazaron más de 40 sentencias print() por logging con niveles (INFO, WARNING, ERROR) y formato timestamp, facilitando la auditoría de eventos.
- Gestión de secretos: las API keys se leen exclusivamente de variables de entorno. El archivo .env está incluido en .gitignore y se creó un .env.example con la documentación completa de variables.

Actualizaciones en el frontend

La interfaz de usuario fue actualizada para reflejar el compromiso con la protección de datos:

- La sección de Políticas de Privacidad incluye referencia explícita a la Ley 1581/2012 e ISO/IEC 27001:2022, enumera los derechos ARCO detallados y lista los documentos de cumplimiento disponibles.
- Los Términos de Uso fueron ampliados con cláusulas sobre cumplimiento normativo y tratamiento de datos.
- El README.md del proyecto fue actualizado con un disclaimer legal y tabla de estado de cumplimiento.

Estado actual y próximos pasos

El proyecto se encuentra en Fase 1 de implementación. Los controles documentales están completos (6 documentos) y los controles técnicos iniciales están implementados (CORS, headers, logging). Pendiente para producción con datos reales: autenticación JWT + RBAC, cifrado de base de datos en reposo, registro RNBD ante la SIC, designación de DPO, y contratos de encargo con proveedores (NVIDIA, GitHub).

Para mayor detalle, consultar el documento completo en docs/CUMPLIMIENTO_LEY1581_ISO27001.md.

Enlaces y recursos

La documentación completa del proyecto está disponible en el repositorio de GitHub del equipo.

Documentación completa:

Enlaces y recursos

La documentación completa del proyecto, el código fuente y la landing interactiva están disponibles públicamente en GitHub, sin necesidad de iniciar sesión.

- Landing interactiva del proyecto (workflow, métricas, documentación):
<https://jaoliverosm.github.io/Capstone-/>
- Repositorio de la aplicación LINE (backend FastAPI, frontend, modelos):
<https://github.com/jaoliverosm/LINE>
- Repositorio completo del proyecto (notebooks, modelos, datasets sintéticos, informes):
<https://github.com/jaoliverosm/Capstone->
- Documentación completa: carpeta `documentacion` dentro del repositorio Capstone-

Equipo SICortex

Jefersson Aldair Oliveros (líder del proyecto)

Arquitectura técnica, ingeniería de variables, desarrollo y validación de los modelos CNN y XGBoost, integración de NVIDIA Nemotron, desarrollo de la interfaz visual y video pitch final.

Jazmine Acosta

Revisión metodológica, control de calidad del pipeline y supervisión de la documentación técnica.

Isabella Andrea Cuesta Niebles

Limpieza de datasets, validación primaria de los datos y organización de los datos para entrenamiento.

Catalina del Rocío Pantoja Ordóñez

Implementación del modelo Random Forest y soporte en el análisis de hallazgos.

Iván Yesid Cristancho Plata

Organización del repositorio en GitHub, apoyo en la integración de XGBoost y Random Forest, y soporte en la documentación visual (diapositivas).

Cronograma de ejecución

Fase 1 (13-19 de julio): datos y modelos base — completado

- Limpieza y análisis exploratorio: integración de las cinco fuentes en el dataset maestro.
- CNN + transfer learning: entrenamiento de MobileNetV2 con tabular-to-image.
- XGBoost: modelo de contraste tabular.
- Random Forest: modelo adicional para comparación.

Fase 2 (20-24 de julio): modelado avanzado — completado

- Búsqueda de hiperparámetros y validación cruzada para XGBoost.
- NVIDIA Nemotron: integración como modelo utilizable con selector en la interfaz.

Fase 3 (24-26 de julio): interfaz y batch — completado

- Aplicativo visual amigable para el auditor médico.
- Importación masiva con procesamiento por lotes.
- Filtros de resultados por recomendación.

Fase 4 (27 de julio - 2 de agosto): consolidación — completado

- Informe técnico final, comparación final de los cuatro enfoques, repositorio organizado, interfaz pulida y documentación completa.

Fase 5 (3-4 de agosto): cierre — en progreso

- Guion y grabación del video pitch (3 minutos), checklist final y entrega en la plataforma del Capstone.

Conclusiones

El proyecto LINE logró desarrollar un sistema completo de auditoría médica digital que integra cuatro enfoques de inteligencia artificial (CNN, Random Forest, XGBoost y NVIDIA Nemotron) para detectar inconsistencias entre la historia clínica y la prefacturación antes del envío a cobro.

Entre los logros principales se destacan el entrenamiento de una CNN MobileNetV2 mediante transfer learning como requisito del curso; la implementación de Random Forest como modelo de comparación para evaluar la conveniencia de un enfoque tabular; la optimización de XGBoost como modelo final de producción, con el mejor desempeño de los cuatro enfoques (AUC-ROC = 0.898); la integración de NVIDIA Nemotron como capa de validación cualitativa y razonamiento clínico; el desarrollo de una interfaz visual completa con análisis individual e importación masiva de hasta 20,000 registros; un

selector de modelos sincronizado en toda la aplicación; filtros de resultados por recomendación; y una documentación técnica completa acompañada de un flujo de trabajo visual interactivo.

Con base en la comparación cuantitativa presentada en la sección de Resultados, **XGBoost es el modelo recomendado para el flujo de producción** por su mejor desempeño global y su alta precisión, que reduce los falsos positivos en las alertas dirigidas al equipo auditor. La CNN permanece disponible en la aplicación como cumplimiento del requisito de transfer learning y como alternativa comparativa para el usuario.

En términos de impacto potencial, el sistema apunta a una reducción significativa de las glosas por sobrefacturación, la recuperación de ingresos por servicios no facturados, la optimización del proceso de auditoría médica y la transición de una auditoría retrospectiva hacia una validación preventiva. El sistema está listo para producción y puede migrarse a bases de datos empresariales (SQL Server o MySQL) siguiendo la guía de migración proporcionada.

*Proyecto desarrollado para Health & Life IPS SAS — Capstone Sistemas Inteligentes y Computacionales 2025 —
Samsung Innovation Campus & Universidad del Rosario*